Processos de ML

COMPLEXOS

ALTO CUSTO HUMANO

ALTO CUSTO COMPUTACIONAL

RISCOS GRANDES

Auto ML

Automatizar o processo

Reduzir a interferência humana

Melhor a performance computacional

Melhorar a performance dos modelos

Auto ML: Por que?


- **➤** Modelos de Machine Learning mais eficientes
- **▶** Produtos Orientados a Dados
- **▶** Participar de Competições de Machine Learning

Auto ML: Tunning!




- Não se trata apenas de automatizar, mas automatizar buscando melhor performance
- ➤O objetivo é que o Auto ML consiga performance melhor do que um humano

Processo de ML



Treinamento

Treinamento





Simulando. Identificar Fraudes em Varejo

10 Mil transações por dia

Valor médio R\$ 100,00

Falsos Positivos: 1%

Falsos Negativos: 0,5%

Perda de Negócios

Perda de Capital

	Falsos Positivos	Falsos Negativos	Total	
Dia	10.000	5.000	15.000	
Mês	300.000	150.000	450.000	



Restrições



Performance do modelo




Tempo de treinamento



Recursos computacionais (memória, CPU)

Treinamento



Treinamento

Melhora nos Falsos Positivos em 0,5 %



Simulando...

10 Mil transações por dia

Valor médio R\$ 100,00

Falsos Positivos: 0,5%


Falsos Negativos: 0,5%

	Falsos Positivos	Falsos Negativos	Total	
Dia	10.000	5.000	15.000	
Mês	300.000	150.000	450.000	

	Falsos Positivos	Falsos Negativos	Total	
Dia	5.000	5.000	10.000	
Mês	150.000	150.000	300.000	



Treinamento



Treinamento

Melhora nos Falsos Positivos em 0,5 %



Classificadores

Batch size [10-1000]


Estimator [4]

Search Algorithm [8]

Use ADTree [true/false]

Rede Bayesiana

Grafo de Dependências



Tabelas de Distribuição de Probabilidade

class credit_amour	t duration	other_parties	'real estate'	'life insura	car	'no known
good Y(-inf-3913.5]	" "\(-inf-15.5)\	none	0,422	0,224	0,261	0,094
			0,423	0,346	0,192	0,031
good Y(-inf-3913.5)	" "(-inf-15.5)\"	guarantor	0,722	0,241	0,019	0,019
			0,229	0,229	0,437	0,10
good Y(-inf-3913.5]	7 (15.5-inf)('co applicant'	0,278	0,167	0,167	0,389
			0,536	0,179	0,179	0,107
good Y(3913.5-inf)	" "(-inf-15.5)\"	none	0,219	0,219	0,281	0,28
			0,25	0,25	0,25	0,2
good Y(3913.5-inf)	" "(-inf-15.5)\"	guarantor	0,167	0,5	0,167	0,16
			0,106	0,24	0,421	0,23
good Y(3913.5-inf)		'co applicant'	0,214	0,071	0,357	0,35
			0,417	0,417	0,083	0,08
bad Y(-inf-3913.5]			0,257	0,27	0,336	0,13
			0,375	0,125	0,375	0,12
bad Y(-inf-3913.5]	" "\(-inf-15.5)\"	guarantor	0,167	0,5	0,167	0,16
			0,272	0,203	0,361	0,16
bad Y(-inf-3913.5]	" "(15.5-inf)\"	'co applicant'	0,389	0,167	0,167	0,27
			0,188	0,438	0,188	0,18
bad Y(3913.5-inf)	" "\(-inf-15.5)\"	none	0,038	0,577	0,038	0,34
			0,167	0,5	0,167	0,16
bad 'Y(3913.5-inf)'	" "\(-inf-15.5)\"	guarantor	0,25	0,25	0,25	0,2
			0,083	0,194	0,383	0,33
bad Y(3913.5-inf)	" Y(15.5-inf)('co applicant'	0,05	0,15	0,35	0,4
			0,5	0,1	0,3	0.







Parâmetros




Batch size [10-1000]

Estimator [4]

Search Algorithm [8]

ADTree [true/false Rede Bayesiana





Tabelas de Distribuição de Probabilidade

class	credit	amount	duration	other_parties	'real estate'	Tife insura	car	'no known
good	Y(-inf-	3913.5]*	Y(-inf-15.5)\"	none	0,422	0,224	0,261	0,094
					0,423	0,346	0,192	0,038
good	Y(-inf-	3913.5]*	Y(-inf-15.5]\"	guarantor	0,722	0,241	0,019	0,019
					0,229	0,229	0,437	0,104
good	Y(-inf-	3913.5]\"	"(15.5-inf)\"	'co applicant'	0,278	0,167	0,167	0,389
					0,536	0,179	0,179	0,107
good	1(391	3.5-inf)\"	Y(-inf-15.5]\"	none	0,219	0,219	0,281	0,281
					0,25	0,25	0,25	0,25
good	1(391	3.5-inf)\"	Y(-inf-15.5]\"	guarantor	0,167	0,5	0,167	0,167
					0,106	0,24	0,421	0,232
good	1(391	3.5-inf)\"	Y(15.5-inf)\"	'co applicant'	0,214	0,071	0,357	0,357
					0,417	0,417	0,083	0,083
bad	Y(-inf-	3913.5]\"	Y(-inf-15.5]\"	none	0,257	0,27	0,336	0,138
					0,375	0,125	0,375	0,125
bad	Y(-inf-	3913.5]\"	Y(-inf-15.5]\"	guarantor	0,167	0,5	0,167	0,167
					0,272	0,203	0,361	0,163
				'co applicant'	0,389	0,167	0,167	0,278
					0,188	0,438	0,188	0,188
bad	1(391	3.5-inf)\"	Y(-inf-15.5]\"	none	0,038	0,577	0,038	0,346
					0,167	0,5	0,167	0,167
bad	1(391	3.5-inf)\"	Y(-inf-15.5]\"	guarantor	0,25	0,25	0,25	0,25
					0,083	0,194	0,383	0,339
bad	7(391	3.5-inf)\"	Y(15.5-inf)\"	'co applicant'	0,05	0,15	0,35	0,45
					0,5	0,1	0,3	0,1







Diferenças

Hiper parâmetros são normalmente configurados pelos implementadores do classificador, antes do processo de treino. Ex: Cientista de Dados

Parâmetros são configurados pelo algoritmo, durante o processo de treino

Hiper Parâmetros

Hiper Parâmetros de Modelo: Interferem na performance do modelo Hiper Parâmetros de Algoritmo: Não interfere na performance do modelo, mas do processo de aprendizado


Domínio

Inteiros: Epochs

Valores Reais: Learning Rate

Binários: Normalizar Atributos

Categóricos: Estimador



Hiper parâmetros condicionais A escolha de um depende ou invalida outro

Um método de busca depende do avaliador de atributo

Parâmetros

Hiper parâmetros


Batch size [10-1000]


Estimator [4]

Search Algorithm [8]

ADTree [true/false Rede Bayesiana







Probability Distribution Table For property_magnitude								×	
class	credi	_amount	duration	other_parties	'real estate'	'life insura	car	'no known	
good	Y(-inf	3913.5]\"	Y(-inf-15.5]V	none	0,422	0,224	0,261	0,094	
					0,423	0,346	0,192	0,038	
good	Y(-inf	3913.5](Y(-inf-15.5]V	guarantor	0,722	0,241	0,019	0,019	
					0,229	0,229	0,437	0,104	
good	Y(-inf	3913.5]\"	"(15.5-inf)\"	'co applicant'	0,278	0,167	0,167	0,389	
					0,536	0,179	0,179	0,107	
good	1(39	13.5-inf)(*	Y(-inf-15.5]V	none	0,219	0,219	0,281	0,281	
					0,25	0,25	0,25	0,25	
good	1(39)	13.5-inf)(*	Y(-inf-15.5]V	guarantor	0,167	0,5	0,167	0,167	
					0,106	0,24	0,421	0,232	
good	1(39	13.5-inf)(*	1(15.5-inf)/1	'co applicant'	0,214	0,071	0,357	0,357	
					0,417	0,417	0,083	0,083	
bad	Y(-inf	-3913.5]\"	Y(-inf-15.5]V	none	0,257	0,27	0,336	0,138	
					0,375	0,125	0,375	0,125	
bad	Y(-inf	3913.5](Y(-inf-15.5]V	guarantor	0,167	0,5	0,167	0,167	
					0,272	0,203	0,361	0,163	
bad	Y(-inf	-3913.5]\"	"((15.5-inf)\"	'co applicant'	0,389	0,167	0,167	0,278	
					0,188	0,438	0,188	0,188	
bad	1(39	13.5-inf)(*	Y(-inf-15.5]V	none	0,038	0,577	0,038	0,346	
					0,167	0,5	0,167	0,167	
bad	1(39)	13.5-inf)(*	Y(-inf-15.5]V	guarantor	0,25	0,25	0,25	0,25	
					0,083	0,194	0,383	0,339	
bad	7(39	13.5-inf)(*	"(15.5-inf)\"	'co applicant'	0,05	0,15	0,35	0,45	
				quarantor	0.5	0.1	0.3	0.1	







Conclusão:

A definição ótima dos hiper parâmetros é vital para a performance do modelo!

Mas quais valores para escolher para os hiper parâmetros?

E será que o classificador que eu estou usando é o melhor?

Hiper Parâmetros

Existem boas práticas, regras gerais, valores default Exemplo, para topologia de uma RNA:

$$t = \frac{a+c}{2}$$

Porém:

- O número de configurações é muito grande
- O custo computacional é muito alto